

La equivalencia de gauge no sobrevive a la cuantización: órbita valor-salida, cota del producto de normas y consecuencias para los métodos rotacionales

Manuel Muñoz Plá

Investigador independiente — Sevilla, España

ORCID: 0009-0000-5714-912X mmunozpl@uoc.edu

Septiembre de 2026

Resumen

Los métodos de cuantización rotacional explotan una invariancia computacional del sector valor-salida de la atención: rotar el par $(\mathbf{W}_v, \mathbf{W}_O)$ sin alterar la función. Esa invariancia es un subgrupo de una órbita mayor $GL(d_h)$ por cabeza, certificada en [1]— y la práctica la restringe dos veces: a rotaciones ortogonales, y compartidas entre las cabezas de la capa. Aquí se mide qué compran ambas restricciones sobre el error de cuantización del circuito OV en dos arquitecturas (Pythia-410M y un ViT-B/16 afinado), con un cuantizador deliberadamente simple que aísla la variable de interés. Tres resultados. Dentro del subgrupo ortogonal la órbita es plana: el rango de error entre rotaciones queda en $\times 1,005$ – $1,02$ en mediana, y el gauge entrenado ya está a $\times 1,02$ – $1,04$ del mejor punto muestreado. La libertad por-cabeza mejora en un 1,3 % a la rotación compartida, por debajo del listón que el diseño fijó como material. Y en la familia GL muestreada, aumentar la anisotropía eleva el error de forma monótona, hasta $\times 15$ en mediana y $\times 10^5$ en el extremo. El mecanismo admite forma cerrada: el error queda acotado por el producto de las normas de los factores transformados, y la aproximación que se sigue de la cota predice exponente uno, con 0,998 medido sobre dos familias de gauge, de modo que la cola catastrófica resulta ser la dispersión del condicionamiento transmitida por esa relación. La cota nombra además la frontera del espacio de diseño, que no separa lo ortogonal de lo no ortogonal: la clase conforme ortogonal deja invariante por identidad el factor p de la cota, el punto balanceado —no ortogonal— minimiza la cota sobre la órbita entera, y el gauge entrenado queda a un 1,1–1,5 % de ese óptimo. Una validación end-to-end confirma la llanura en exactitud real: identidad, mejor y peor rotación muestreada y punto balanceado caen en 0,10 puntos porcentuales, indistinguibles por McNemar pareado sobre las mismas 5000 imágenes. El contraste que carga el peso es otro. Un gauge general de escala 2, sin cuantizar, predice la misma clase que la identidad en las 5000 imágenes, sin una sola discrepancia. Cuantizado a int4 cae a 0,0082, por debajo del azar nominal sobre 100 clases, y coincide entonces con la identidad en 44 imágenes. El control aísla la causa: la equivalencia de gauge es exacta en aritmética real y no sobrevive a la rejilla. El resultado acota además dónde no está la ganancia de los métodos rotacionales —no en el paisaje de pesos de la órbita—, coherente con su atribución habitual a los outliers de activación.

Palabras clave: cuantización, invariancia computacional, órbita de gauge, circuito OV, atención multi-cabeza, RTN.

1. Motivación

Una libertad de gauge recorre el sector valor-salida de toda cabeza de atención: la sustitución $\mathbf{W}_v \rightarrow \mathbf{W}_v \mathbf{R}$, $\mathbf{W}_O \rightarrow \mathbf{R}^{-1} \mathbf{W}_O$, con $\mathbf{R}$ invertible en $GL(d_h)$, deja la salida de la capa y el circuito $OV = \mathbf{W}_O \mathbf{W}_v$ exactamente intactos. Por legibilidad se omite el sesgo de valor; cuando existe,

se transforma con la proyección de valor, y en la convención de almacenamiento de sección 2 eso es $\mathbf{b}_v \mapsto \mathbf{R}^\top \mathbf{b}_v$. Omitirlo no deja la salida intacta, y sección 3.5 lo mide. En [1] esa órbita se certifica por cabeza y se mide su consecuencia para las lecturas geométricas de $\mathbf{W}_O$. Aquí interesa su otra cara. La cuantización rotacional —QuaRot [2] con rotaciones de Hadamard fijas, SpinQuant [3] con rotaciones aprendidas— explota precisamente esta invariancia para redistribuir los pesos antes de cuantizarlos: su rotación R_2 opera sobre el par valor-salida, restringida a matrices ortogonales y compartida entre todas las cabezas de la capa.

La práctica, por tanto, elige un punto de la órbita imponiendo dos restricciones —ortogonalidad y compartición— sin que exista una caracterización de qué costaría no imponerlas, ni de cuánto queda sobre la mesa dentro de ellas. Aquí se miden ambas cosas con el marco formal en la mano. Tres preguntas concretas, con sus reglas de lectura fijadas antes de ver dato alguno: **Q1**, ¿cuánto varía el error de cuantización del circuito a lo largo de la órbita ortogonal? **Q2**, ¿dónde queda el gauge entrenado —los pesos tal como el optimizador los dejó— respecto a ese rango? **Q3**, ¿qué compra la libertad por-cabeza frente a la rotación compartida que la práctica usa?

Una declaración de género antes de empezar: esto es una caracterización del espacio, no un método. No hay GPTQ, no hay rotaciones aprendidas, no hay comparación con el estado del arte de cuantización. El cuantizador es deliberadamente el más simple posible porque el objeto de medida es el gauge, no el cuantizador.

2. Diseño experimental

Modelos y objetos. Dos arquitecturas con el mismo $d_h = 64$: Pythia-410M (24 capas, 16 cabezas; pesos públicos, sin entrenamiento propio) y un ViT-B/16 afinado en ImageNet-100 (12 capas, 12 cabezas; la semilla 42 de [1]). Una realización por modelo: la dispersión de interés es entre gauges, cabezas y capas, no entre semillas, y se declara como tal. Se cuantiza el par $(\mathbf{W}_v^{(h)}, \mathbf{W}_O^{(h)})$ por cabeza. Con la orientación de almacenamiento de las capas lineales, $\mathbf{v} = \mathbf{x}\mathbf{W}_v^\top + \mathbf{b}_v$, el gauge de sección 1 se escribe $\mathbf{W}_v \mapsto \mathbf{R}^\top \mathbf{W}_v$ y $\mathbf{W}_O \mapsto \mathbf{W}_O \mathbf{R}^{-\top}$, que es la forma usada a partir de sección 3.4. La referencia es el circuito $\mathbf{M}_h = \mathbf{W}_O^{(h)} \mathbf{W}_v^{(h)}$ exacto en fp64 y la métrica el error relativo de Frobenius $e = \|\hat{\mathbf{M}} - \mathbf{M}\|_F / \|\mathbf{M}\|_F$, con $\hat{\mathbf{M}}$ recompuesto en fp64. Toda la aritmética de gauges es en fp64: con $\mathbf{R}$ fuerte, la inversa en precisión simple amplifica el error por el número de condición y contamina la medida —el fenómeno que la sección 3.4 convierte en resultado.

Cuantizador y regímenes. RTN simétrico por canal (fila), a int4 e int8, sin calibración con datos. Por capa y cabeza: identidad (los pesos tal cual); ortogonal por-cabeza ($K = 32$ rotaciones Haar independientes); ortogonal compartida (las mismas $K = 32$ en todas las cabezas de la capa, el régimen de SpinQuant); y GL general ($\mathbf{R} = \text{ruido} + \text{escala} \cdot \mathbf{I}$, escala $\in \{2, 8, 32\}$, $K = 32$ por escala —escala baja denota gauge fuerte y condición alta). En total 170 016 mediciones (123 648 en Pythia, 46 368 en ViT-B), con conteos exactos y cero claves duplicadas.

Compuertas previas. Tres, y el barrido no corre sin ellas: el gauge ortogonal sin cuantizar reproduce el circuito en el suelo de la doble precisión (peor caso $1,9 \times 10^{-15}$); int8 sobre la identidad da un error un orden de magnitud menor que int4 (ratio $\approx 18\times$ en ambos modelos); y el cuantizador es exactamente idempotente.

Reglas de lectura, fijadas a ciegas. Q1: el rango ortogonal es “material” si el cociente peor/identidad alcanza $\times 2$, “estrecho” si queda bajo $\times 1,25$. Q2: la identidad está “lejos del suelo” si supera $\times 1,5$ el mejor punto muestreado, “cerca” si queda bajo $\times 1,1$. Q3: la mejora por-cabeza es “material” si su mediana alcanza el 20 % relativo, “nula” si queda bajo el 5 %. Cualquier desenlace preespecificado se reporta, salga como salga.

Una cuarta regla, la de sección 3.5, se fijó *después* de ver Q1 —una actualización explícita, no una desviación silenciosa—. El prereg original pedía coherencia de signo (mejor $\geq$ identidad




Figura 1: Distribución del error relativo del circuito e por régimen de gauge (bits=4), con la mediana de la identidad como referencia horizontal. Las cajas sin outliers muestran la llanura entre identidad y ambos regímenes ortogonales.

$\geq$ peor) entre tres forwards. Q1 mostró que esos tres puntos difieren en e un 2–8 % nada más, distancia que tres forwards no resuelven como signo sin confundir ruido con señal. La regla actualizada, fijada antes de correr los forwards: si el rango ortogonal es $< \times 1,25$ (lo es), la predicción pasa a ser indistinguibilidad, y esa indistinguibilidad, de confirmarse, es la confirmación de Q1 en exactitud real. Compara los tres puntos *entre sí* por rango: no predice ni descarta una diferencia sistemática entre la identidad y el conjunto ortogonal, que de aparecer sería observación distinta, no preregistrada. Se añadieron además forwards post-hoc declarados y marcados como tales en la tabla: un gauge general de escala 2, con y sin cuantizar, para anclar la cola tóxica en una cifra de exactitud y aislar su causa, y el punto balanceado de corolario 2.

3. Resultados

3.1. La órbita ortogonal es plana (Q1)

Por celda (capa, cabeza, anchura), el cociente entre el peor error ortogonal muestreado y el error de la identidad queda en “estrecho” en la totalidad de las celdas de ambos modelos: 768 de 768 en Pythia (mediana $\times 1,02$, rango $[0,97, 1,08]$) y 288 de 288 en ViT-B (mediana $\times 1,005$, rango $[0,76, 1,06]$). Elegir una u otra rotación ortogonal apenas mueve el error de cuantización de los pesos: el paisaje dentro del subgrupo es una llanura. El extremo inferior del rango de ViT-B (0,76) recoge celdas donde incluso la peor rotación muestreada batió a la identidad —el único asomo de estructura, que Q2 recoge.

Figura 1 traza la distribución de e por régimen —identidad, ortogonal compartida, ortogonal por-cabeza, GL general— con la mediana de la identidad marcada como línea de referencia horizontal: las tres primeras cajas se solapan sobre esa línea en ambos modelos. La llanura es visible de un vistazo antes de leer una sola cifra, y el contraste con la cuarta caja (GL general, sección 3.4) es inmediato.

3.2. El gauge entrenado ya está junto al suelo del producto de normas (Q2)

El cociente entre el error de la identidad y el mejor punto muestreado en cualquier régimen queda en “cerca” en 768 de 768 celdas de Pythia (mediana $\times 1,02$, máximo $\times 1,10$) y en 237 de 288 de ViT-B (mediana $\times 1,04$). Las 51 restantes quedan entre medias, con máximo $\times 1,44$ y ninguna en “lejos”. La lectura es coherente con Q1: si la órbita es plana, la identidad no puede estar lejos de nada. El entrenamiento no optimiza cuantizabilidad —nada en su objetivo lo pide— pero a estas escalas tampoco la necesita: el margen que una rotación óptima podría recuperar sobre los pesos es de un dígito porcentual, con la excepción moderada de una fracción de cabezas del ViT afinado (hasta $\times 1,44$), insuficiente para cruzar ningún listón. El cociente compara la




Figura 2: Mediana por capa del error del mejor-de- K por-cabeza frente a la mejor rotación compartida, una sola por capa (bits=4). Las curvas corren paralelas, con un hueco de algo más del uno por ciento en las 24 y 12 capas respectivamente.

identidad contra el *mejor* punto muestreado, y corolario 2 cierra la otra mitad de la pregunta: el mínimo del producto de normas sobre la órbita entera, alcanzable y calculable, queda a un 1,5 % en Pythia y a un 1,1 % en ViT-B. El gauge entrenado no está cerca del mejor de treinta y dos muestras, está cerca del óptimo del producto de normas.

3.3. La libertad por-cabeza compra muy poco (Q3)

El régimen compartido admite una sola R por capa, y así se evalúa: de las $K = 32$ rotaciones compartidas se elige la que minimiza el error medio sobre las cabezas de esa capa —el objetivo agregado que un método rotacional optimizaría— y se compara cabeza a cabeza contra el mejor-de- K por-cabeza. La mediana de mejora relativa es 1,32 % en Pythia y 1,38 % en ViT-B, con percentiles 10 y 90 en $[0,13, 2,46]$ y $[0,15, 2,62]$: “nulo” por el listón preregistrado del 5 %. Del lado de los pesos, la compartición de rotación entre cabezas —la restricción de SpinQuant— queda validada: la libertad adicional que la órbita permite por cabeza compra algo más de un uno por ciento de error de circuito, lejos del umbral que el diseño fijó como material.

Corrección de implementación. La primera versión de esta lectura tomaba, dentro del brazo compartido, el mínimo por cabeza sobre las K muestras. Cada cabeza acababa eligiendo un índice distinto, y el brazo dejaba de ser compartido: el contraste comparaba libertad por-cabeza contra libertad por-cabeza y daba, por construcción, una mejora de $-0,03$ % y $-0,06$ %. La pregunta Q3 y su listón son los preregistrados. Lo corregido es la implementación de “compartida”. El código publicado conserva ambas columnas para que la corrección sea auditable.

Se preregistró la limitación de este contraste: comparar mejores-de- K aleatorios no es comparar óptimos. El refinamiento local sobre la variedad ortogonal quedó condicionado a que Q1/Q2 mostraran estructura que refinar. Con la llanura medida, no procede y no se ejecutó.

Figura 2 traza la mediana por capa de ambas curvas —por-cabeza y compartida—. Corren paralelas en los dos modelos, separadas por el mismo hueco de algo más del uno por ciento en cada capa, sin capa donde el hueco se abra. El veredicto de Q3 se sostiene capa a capa y no solo en el agregado: la ventaja por-cabeza existe, es uniforme y es pequeña.

3.4. La región de p grande es tóxica —y por qué

En la familia GL muestreada, el error crece de forma monótona y severa con la fuerza del gauge. En int4, la mediana de e pasa de 0,19 (escala 32, gauge suave, el mismo 0,19 de la identidad a dos decimales) a 1,10 (escala 8) y 2,85 (escala 2) en Pythia —0,19, 1,08 y 2,72 en ViT-B—, con máximos de $3,3 \times 10^5$ y $9,5 \times 10^3$ respectivamente. En int8 el patrón es idéntico un orden de

magnitud abajo. Es la contrapartida cuantitativa del requisito de fp64: el fenómeno que allí se evita como contaminación numérica aparece aquí medido como propiedad del espacio.

El mecanismo admite forma cerrada. Bajo el gauge los factores pasan a $\mathbf{W}'_v = \mathbf{R}^\top \mathbf{W}_v$ y $\mathbf{W}'_O = \mathbf{W}_O \mathbf{R}^{-\top}$, y el circuito recompuesto tras cuantizar es $\hat{\mathbf{M}} = \mathbf{M} + \Delta \mathbf{W}_O \mathbf{W}'_v + \mathbf{W}'_O \Delta \mathbf{W}_v + \Delta \mathbf{W}_O \Delta \mathbf{W}_v$. El cuantizador que aquí se usa acota su propio error relativo, y esa cota no depende de la escala de los pesos.

Lema 1 (Error relativo de RTN por fila). *Sea $\mathbf{W} \in \mathbb{R}^{m \times n}$ y sea $\hat{\mathbf{W}}$ su versión cuantizada por RTN simétrico por fila con b bits, es decir $\hat{\mathbf{w}} = s \text{round}(\mathbf{w}/s)$ con $s = \|\mathbf{w}\|_\infty / q_{\max}$ y $q_{\max} = 2^{b-1} - 1$ para cada fila no nula $\mathbf{w}$. Entonces*

$$\|\Delta \mathbf{W}\|_F \leq \frac{\sqrt{n}}{2q_{\max}} \|\mathbf{W}\|_F, \quad (1)$$

y el factor depende solo de la longitud de la fila y de la anchura.

Demostración. Para una fila, el redondeo a la rejilla de paso s da $|\Delta w_i| \leq s/2$ en cada componente, y el recorte no actúa porque $|w_i/s| \leq q_{\max}$ por construcción de s . Entonces $\|\Delta \mathbf{w}\|_2 \leq \sqrt{n} s/2 = \sqrt{n} \|\mathbf{w}\|_\infty / (2q_{\max}) \leq \sqrt{n} \|\mathbf{w}\|_2 / (2q_{\max})$, usando $\|\cdot\|_\infty \leq \|\cdot\|_2$. Una fila nula cumple $\Delta \mathbf{w} = \mathbf{0}$. Sumando los cuadrados sobre las filas, $\|\Delta \mathbf{W}\|_F^2 \leq (\sqrt{n}/(2q_{\max}))^2 \|\mathbf{W}\|_F^2$. $\square$

Lema 1 da la hipótesis que la proposición siguiente necesita, con $\delta = \sqrt{n}/(2q_{\max})$ fijo dentro de cada factor. Eso alcanza para una cota, y no solo para una estimación.

Proposición 1 (Cota del producto de normas). *Sean $\mathbf{W}_v$ y $\mathbf{W}_O$ de rango completo, $\mathbf{M} = \mathbf{W}_O \mathbf{W}_v$ y $\mathbf{R} \in GL(d_h)$. Si la cuantización cumple $\|\Delta \mathbf{W}'_v\|_F \leq \delta_v \|\mathbf{W}'_v\|_F$ y $\|\Delta \mathbf{W}'_O\|_F \leq \delta_O \|\mathbf{W}'_O\|_F$, entonces*

$$e(\mathbf{R}) = \frac{\|\hat{\mathbf{M}} - \mathbf{M}\|_F}{\|\mathbf{M}\|_F} \leq (\delta_v + \delta_O + \delta_v \delta_O) g(\mathbf{R}), \quad g(\mathbf{R}) = \frac{\|\mathbf{W}_O \mathbf{R}^{-\top}\|_F \|\mathbf{R}^\top \mathbf{W}_v\|_F}{\|\mathbf{M}\|_F}. \quad (2)$$

Tomados δ_v y δ_O como cotas uniformes sobre la familia de gauges considerada, toda la dependencia explícita del gauge queda en g .

Demostración. La descomposición de $\hat{\mathbf{M}} - \mathbf{M}$ de arriba, la desigualdad triangular y $\|\mathbf{AB}\|_F \leq \|\mathbf{A}\|_F \|\mathbf{B}\|_F$ dan $\|\hat{\mathbf{M}} - \mathbf{M}\|_F \leq (\delta_O + \delta_v + \delta_O \delta_v) \|\mathbf{W}'_O\|_F \|\mathbf{W}'_v\|_F$. Se divide por $\|\mathbf{M}\|_F$, que el gauge deja fijo. $\square$

Normalizando por su valor en la identidad el único factor de ecuación (2) que depende del gauge queda la variable que el resto de la sección mide,

$$p(\mathbf{R}) \equiv \frac{g(\mathbf{R})}{g(\mathbf{I})} = \frac{\|\mathbf{W}_O \mathbf{R}^{-\top}\|_F \|\mathbf{R}^\top \mathbf{W}_v\|_F}{\|\mathbf{W}_O\|_F \|\mathbf{W}_v\|_F}. \quad (3)$$

Dos cotas no se dividen: de $e(\mathbf{R}) \leq C g(\mathbf{R})$ y $e(\mathbf{I}) \leq C g(\mathbf{I})$ no se sigue $e/e_0 \leq p$. Si el factor efectivo de cuantización y la holgura de la cota varían poco entre gauges, la cota sugiere $e(\mathbf{R})/e(\mathbf{I}) \simeq p(\mathbf{R})$, exponente uno sobre el papel y sin ajustar nada. Esa es la hipótesis que el resto de la sección contrasta, y no un corolario de proposición 1. Dos consecuencias inmediatas nombran los dos extremos del espacio de diseño.

Corolario 1 (La clase conforme ortogonal es neutra para la cota). *Para $\mathbf{R} = c\mathbf{Q}$ con $c > 0$ y $\mathbf{Q}$ ortogonal se cumple $g(c\mathbf{Q}) = g(\mathbf{I})$, es decir $p \equiv 1$ sobre la clase entera, para todo par $(\mathbf{W}_v, \mathbf{W}_O)$.*

Demostración. La norma de Frobenius es invariante ortogonal, así que $\|(c\mathbf{Q})^\top \mathbf{W}_v\|_F = c \|\mathbf{W}_v\|_F$ y $\|\mathbf{W}_O (c\mathbf{Q})^{-\top}\|_F = c^{-1} \|\mathbf{W}_O\|_F$. El factor c se cancela en el producto. $\square$

Corolario 2 (Los mínimos de la cota). $\min_{\mathbf{R} \in GL(d_h)} g(\mathbf{R}) = \|\mathbf{M}\|_*/\|\mathbf{M}\|_F$. El conjunto de mínimos es la familia balanceada del par —la que el trabajo previo [1] caracteriza como mínimo de $\|\mathbf{R}^\top \mathbf{W}_v\|_F^2 + \|\mathbf{W}_O \mathbf{R}^{-\top}\|_F^2$ — compuesta con los escalados recíprocos $(\mathbf{A}, \mathbf{B}) \rightarrow (c\mathbf{A}, c^{-1}\mathbf{B})$, $c > 0$, y ninguno más. Es entonces una sola órbita de la clase conforme ortogonal de corolario 1, que reaparece aquí como el grupo que lleva un mínimo a otro.

Demostración. Para toda factorización $\mathbf{M} = \mathbf{AB}$, la desigualdad de Hölder para normas de Schatten con $1 = \frac{1}{2} + \frac{1}{2}$ da $\|\mathbf{M}\|_* \leq \|\mathbf{A}\|_F \|\mathbf{B}\|_F$. Con $\mathbf{M} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ de rango d_h , el par balanceado $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}^{1/2}$, $\mathbf{B} = \mathbf{\Sigma}^{1/2}\mathbf{V}^\top$ cumple $\|\mathbf{A}\|_F \|\mathbf{B}\|_F = \text{tr } \mathbf{\Sigma} = \|\mathbf{M}\|_*$ y alcanza la igualdad. El producto es invariante bajo $(\mathbf{A}, \mathbf{B}) \rightarrow (c\mathbf{A}, c^{-1}\mathbf{B})$, de modo que todo reescalado recíproco de un mínimo es un mínimo, aunque rompa el balance para $c \neq 1$.

Recíprocamente, sea $(\mathbf{A}, \mathbf{B})$ un mínimo cualquiera y $c^* = (\|\mathbf{B}\|_F/\|\mathbf{A}\|_F)^{1/2}$. El par $(c^*\mathbf{A}, (c^*)^{-1}\mathbf{B})$ conserva el producto y sigue siendo mínimo, y sus dos normas valen ahora $\|\mathbf{M}\|_*^{1/2}$. Su suma de cuadrados es $2\|\mathbf{M}\|_*$, el mínimo que el lema del punto balanceado [1] caracteriza, así que ese par es balanceado. Todo mínimo del producto es un reescalado recíproco de uno balanceado. $\square$

La frontera del espacio de diseño queda entonces escrita, y no es la de ortogonal contra no ortogonal. Corolario 1 señala como neutra para la cota la clase conforme ortogonal $\{c\mathbf{Q}\}$ —la misma que el trabajo previo identifica como única inocua para $\mathbf{v}_1(\mathbf{W}_O)$, y de medida nula en $GL(d_h)$ por dimensión, ya que $1 + d_h(d_h - 1)/2 < d_h^2$ para $d_h > 1$ —, y corolario 2 pone suelo a cuánto puede comprar la anisotropía. De esa familia de mínimos se construye un representante balanceado, caracterizado dentro de cada familia de escalado recíproco por igualar las dos normas. Ese suelo se mide: p en el punto balanceado vale 0,985 en Pythia y 0,989 en ViT-B (mediana sobre cabezas), de modo que el gauge entrenado está a un 1,5 % y un 1,1 % del óptimo de la órbita entera en la variable de ecuación (3). El espacio de diseño es asimétrico en su propio interior: por arriba llega a $\times 10^5$, por abajo se agota en el uno por ciento.

El condicionamiento no basta. La predicción se contrastó con un barrido de gauges de condicionamiento controlado —SVD de una gaussiana con el espectro sustituido por uno geométrico entre 1 y κ —, sobre diecinueve puntos de rejilla y con las mismas compuertas de conteo del barrido principal: 642 048 medidas adicionales. La regla de lectura se fijó por escrito antes de correr, y sobre el número de condición el veredicto es **tendencia**, no ley: en int4 la banda con señal abarca solo cuatro puntos de rejilla, y en int8, pese a un R^2 de 0,9997 y a un exponente que coincide en las dos arquitecturas (0,884 en ambas), los residuos conservan curvatura sistemática por encima del listón fijado. La comprobación de consistencia preregistrada falla además: a κ igualado, la familia controlada y la original no coinciden (razón mediana 0,69–0,72 por encima de $\kappa \approx 30$, con 5 de 48 gauges originales dentro del $[p_5, p_{95}]$ de su controlada). El número de condición no es estadístico suficiente: dos gauges igual de mal condicionados y de distinta forma espectral cuantizan distinto.

La ley del producto (adición post-hoc declarada). La variable que sí colapsa las dos familias es la de ecuación (3). Sobre 743 424 medidas de ambas familias, dos modelos y dos anchuras, el ajuste log-log de e/e_0 contra p da exponente 0,9979 con $R^2 = 0,9993$ y separación entre familias de 0,003 en logaritmo. Contra κ , exponente 0,714 y separación 0,167 (figura 4). La derivación y su tolerancia se escribieron antes del contraste, pero la variable se eligió tras ver fallar la de κ : el resultado entra como adición post-hoc declarada, igual que los forwards post-hoc de sección 3.5. Lo sostiene la prueba pareada —cada gauge original contra dieciséis controlados al mismo κ y sobre los mismos pesos—, porque en el ajuste conjunto las familias no cubren el mismo rango de p y su separación mezclaría diferencia con desajuste de rango.

La cola, explicada. Con κ fijado la dispersión dentro de una celda casi desaparece: el peor cociente entre máximo y mediana es $1,27\times$ en Pythia y $1,64\times$ en ViT-B. En la familia original, a




Figura 3: Percentiles (p50/p90/p99/máx) del error del circuito para el régimen GL general, por escala (bits=4). El máximo se dispara por encima del p99 a escala baja.

escala fija, ese cociente es de miles —8 224× en Pythia a escala 2— y coincide casi exactamente con el de κ dentro de esa misma escala (8 181×). La cola catastrófica de figura 3 no es un fenómeno aparte: es la dispersión del condicionamiento dentro de cada escala, transmitida por una ley de exponente uno. Y en el subgrupo ortogonal $p = 1$ exactamente, así que el factor de ecuación (3) no infla: la frontera que separa la llanura de la zona incuantizable queda derivada para el factor de la cota, y el experimento muestra que sigue la transición a la región de error alto.

Figura 3 no usa una caja con outliers ocultos —con mediana 2,85 y máximo $3,3 \times 10^5$ en Pythia a escala 2, esconder la cola sería esconder el titular—. Reporta en su lugar los percentiles p50/p90/p99 y el máximo, explícitos, por escala. El máximo se dispara por encima incluso del p99: la cola es del extremo, no del cuerpo de la distribución.

El punto balanceado: la ley probada por el lado que desinfla. El ajuste de ecuación (3) descansa en familias que inflan p . Corolario 2 permite construir explícitamente un representante con $p < 1$, el punto balanceado, por SVD del circuito en vez de muestrearlo, así que la predicción se puede contrastar fuera del rango ajustado. Dos lecturas quedaron fijadas por escrito antes de correr: el punto balanceado *mejora* si $e_{\text{bal}} < e_{\text{id}}$ en al menos el 90 % de las celdas, y la ley *extrapola* si la mediana de $(e_{\text{bal}}/e_{\text{id}})/p_{\text{bal}}$ cae en $[0,90, 1,10]$.

El resultado separa las dos. La ley extrapola por el listón fijado —mediana 1,042 en Pythia y 1,079 en ViT-B— y el punto balanceado no mejora: el cociente medido es 1,027 y 1,066 en int4, con solo el 7,8 % y el 2,1 % de las celdas por debajo del gauge entrenado. La desviación es de un signo en los dos modelos y en las dos anchuras, y es el precio de pasar de la cota a la aproximación: $e/e_0 \simeq p$ trata el factor efectivo de cuantización como aproximadamente constante entre gauges, y a 1,5 % de recorrido esa suposición ya no alcanza.

La medida importa por otra razón. El punto balanceado es un gauge *no ortogonal* — $d(\mathbf{R}) = 0,089$ en Pythia y 0,076 en ViT-B, con $\text{cond}(\mathbf{R})$ de 1,61 y 1,44—, y su error se queda en $\times 1,03$ y $\times 1,07$ frente a la mediana $\times 15$ y el máximo $\times 10^5$ de la órbita general muestreada. Salir del subgrupo ortogonal no degrada por sí mismo: el parámetro que gobierna es p , y un gauge anisotrópico con $p \simeq 1$ cuantiza como una rotación. Aquí $d(\mathbf{R})$ es la desviación típica de los valores singulares partida por su norma, la distancia a $\{c\mathbf{Q}\}$ que el trabajo previo [1] usa como mando de fuerza del gauge, y vale cero exactamente sobre la clase conforme ortogonal.

3.5. Validación end-to-end

Siete forwards de ViT-B sobre el val limpio completo de ImageNet-100 (5000 imágenes). Cinco con $(\mathbf{W}_v, \mathbf{W}_O)$ en int4 —identidad, mejor y peor gauge ortogonal muestreado, punto balanceado y un gauge general de escala 2— y dos controles sin cuantizar, la identidad y ese mismo gauge




Figura 4: Colapso entre familias (bits=4). Contra κ (izquierda) quedan desplazadas; contra el producto de ecuación (3) (derecha) caen sobre la recta de pendiente uno, dibujada sin ajustar. Adición post-hoc declarada.

general. Los gauges muestreados se reconstruyen exactos re-jugando la secuencia del generador que el barrido ya consumió, sin persistir cada rotación, y la reconstrucción se verificó contra el csv del barrido en tres celdas de control (diferencia $< 10^{-9}$). Todos los top-1 están en la tabla 1. Las condiciones se evalúan sobre las mismas imágenes y en el mismo orden, así que cada contraste lleva su prueba pareada: McNemar exacto sobre los discordantes e intervalo del 95 % por bootstrap de imágenes (10 000 remuestreos, semilla fija).

Corrección de implementación. El gauge se aplica al par y al sesgo de valor. Como $\mathbf{v} = \mathbf{x}\mathbf{W}_v^\top + \mathbf{b}_v$, la compensación de $\mathbf{W}_O$ exige $\mathbf{b}_v \rightarrow \mathbf{R}^\top \mathbf{b}_v$, y una versión anterior de esta tabla dejaba el sesgo quieto: sobre un lote sin cuantizar, un gauge ortogonal movía entonces la salida un 57 % relativo y solo el 12 % de los top-1 coincidía. El forward medía otro modelo, y la tabla atribuía a la identidad una ventaja de 2,8 puntos que era ese sesgo. Ahora una compuerta verifica la invariancia del forward *antes* de cuantizar, condición a condición: 4×10^{-7} en los tres gauges bien condicionados y $1,2 \times 10^{-5}$ en el general de escala 2.

Contraste preregistrado: indistinguibilidad ortogonal, confirmada. Mejor y peor gauge ortogonal muestreado dan 0,9306 y 0,9298, y la identidad 0,9308: un rango de 0,10 puntos porcentuales entre los tres. Los tres contrastes pareados son indistinguibles, con McNemar de 0,68, 1,00 y 0,52 y todos los intervalos conteniendo el cero. La identidad queda dentro de la llanura y no fuera, que es la predicción actualizada de Q1 llevada a exactitud real.

Un matiz que el acuerdo de clase predicha deja ver y el top-1 esconde: entre esas condiciones cuantizadas la predicción coincide en el 98,4–98,9 % de las imágenes, no en todas. La cuantización baraja casos concretos aunque la exactitud agregada no se mueva. Indistinguible en exactitud, por tanto, y no idéntico en predicción.

Adición post-hoc declarada: el punto balanceado. El gauge que corolario 2 construye —no ortogonal, con $\text{cond}(\mathbf{R}) = 1,44$ en este modelo— da 0,9306, a 0,02 puntos de la identidad y con McNemar de 1,00. Salir del subgrupo ortogonal por el lado que la cota predice como bueno no cuesta exactitud. La afirmación «la restricción ortogonal es necesaria» queda refutada por un contraejemplo construido, y en su lugar vale la de corolario 1: lo peligroso es p lejos de uno, y no la ausencia de ortogonalidad.

Adición post-hoc declarada: el colapso GL y su control. El gauge general de escala 2 se mide dos veces, con y sin cuantizar. Sin cuantizar da 0,9314, el mismo top-1 que la identidad en fp32, y el contraste pareado va más lejos que el top-1: **la clase predicha coincide en las 5000 imágenes**, sin una sola discrepancia. La red predice exactamente lo mismo, imagen a imagen, bajo un cambio de coordenadas de condición alta. Cuantizado a int4 da 0,0082, por debajo del

Tabla 1: Validación end-to-end sobre ViT-B, val limpio de ImageNet-100 (5000 imágenes). La columna de invariancia es la desviación relativa del forward bajo el gauge *antes* de cuantizar. Los seis primeros contrastes son indistinguibles por McNemar pareado. El séptimo, identidad contra gauge general con ambos en int4, es el único distinto, y con el sexto aísla la causa: iguales sin cuantizar, distintos cuantizados.

Condición	Bits	Top-1	Invariancia	Estatus
Identidad	—	0,9314	—	control
Identidad	4	0,9308	—	referencia
Mejor ortogonal muestreado	4	0,9306	$4,0 \times 10^{-7}$	preregistrado
Peor ortogonal muestreado	4	0,9298	$4,0 \times 10^{-7}$	preregistrado
Punto balanceado	4	0,9306	$4,2 \times 10^{-7}$	post-hoc declarado
GL escala 2	—	0,9314	$1,2 \times 10^{-5}$	control
GL escala 2	4	0,0082	$1,2 \times 10^{-5}$	post-hoc declarado

1,00 % que el azar nominal reparte entre 100 clases, con una caída de 92,26 puntos. El control aísla la causa: el gauge no toca la función y la cuantización la destruye. La equivalencia de gauge es exacta en aritmética real y no sobrevive a la rejilla.

4. Discusión

Lectura conjunta. Los tres resultados componen una asimetría, y la forma cerrada nombra su frontera. Dentro del subgrupo ortogonal, ni el punto (Q1, Q2) ni la granularidad por-cabeza (Q3) mueven de forma material el error de cuantización de los pesos, y la sección 3.5 confirma que tampoco distinguen entre sí la exactitud real del modelo. En la región de p grande, la degradación llega al colapso.

La frontera, sin embargo, no separa lo ortogonal de lo no ortogonal. Corolario 1 deja la clase conforme ortogonal $\{c\mathbf{Q}\}$ exactamente neutra para la cota, y el punto balanceado —anisotrópico, con $d(\mathbf{R}) \simeq 0,08$ — cuantiza como una rotación. Separa la llanura de la región incuantizable el valor de p , y la ortogonalidad es la condición suficiente barata que lo fija en 1 sin calcularlo. Para la cuantización rotacional la implicación se enuncia entonces sin exceso: la restricción ortogonal no es una comodidad de implementación, porque garantiza $p = 1$ por construcción, y su restricción de compartición no deja casi nada sobre la mesa del lado de los pesos. La cota predice el mismo riesgo para una anisotropía con $p \simeq 1$, y el punto balanceado es el caso que la sección 3.5 valida end-to-end. Evaluar p cuesta dos normas de Frobenius.

Implicaciones prácticas. Cuatro guías de diseño se siguen de la caracterización, cada una de su resultado. Primera, de Q3: implementar rotaciones por-cabeza en un método rotacional compra muy poco del lado de los pesos —la restricción compartida de SpinQuant es casi gratis a estas escalas, y multiplicar por H el número de rotaciones almacenadas o aprendidas ofrece muy poco retorno—. Segunda, de Q1–Q2, del punto balanceado y de la validación end-to-end: no gastar presupuesto de búsqueda en optimizar el gauge para el error de pesos. El paisaje es plano y corolario 2 acota cuánto puede mejorar sobre la órbita entera el *factor del producto de normas* desde el gauge entrenado: un 1,5 % en Pythia y un 1,1 % en ViT-B. Sobre el error de RTN esa cota no se traslada, y de hecho el mínimo construido no lo realiza. De ambas cosas juntas se sigue una recomendación empírica, no un teorema: a estas escalas hay poco retorno del lado de los pesos en gastar presupuesto de búsqueda sobre el gauge. El objetivo de la optimización rotacional debe ser el canal de activaciones, que es donde esos métodos reportan su ganancia. Tercera, de la ley del producto: toda reparametrización no ortogonal del sector valor-salida —cirugía de

modelos, fusión, fijado de gauge— produce checkpoints funcionalmente idénticos que pueden ser incuantizables, y p da una estimación sin datos de su riesgo de inflado del error de circuito antes de cuantizar. Basta evaluar p en ecuación (3) sobre los pesos y la transformación: dos normas de Frobenius y una inversión de $d_h \times d_h$, sin datos, sin forwards y sin cuantizar nada. Un pipeline que reciba checkpoints transformados por terceros puede rechazarlos, revertir la transformación o presupuestar la pérdida con esa cifra en la mano. Con el límite que la tercera valla impone: p es el factor de una cota y no una predicción exacta, y su desviación medida es de un signo. Y cuarta, de corolario 1: una transformación del sector valor-salida con parte anisotrópica pequeña presenta bajo riesgo de inflado del error de circuito según esta cota, y la prueba barata es p y no la ortogonalidad. Fijar el gauge por QR, balancear los factores o reescalar cabezas son operaciones distintas para $v_1(W_O)$ y equivalentes para la cuantización mientras p se quede cerca de uno.

Primera valla: pesos, no activaciones. Este diseño mide el lado de pesos del circuito. Las ganancias que QuaRot y SpinQuant reportan provienen mayormente de la eliminación de outliers de *activación*, un canal que este trabajo no toca por construcción. El resultado no dice que las rotaciones no sirvan; dice, por eliminación del otro canal, que su beneficio no reside en el paisaje de pesos de la órbita —una acotación coherente con la atribución que esos mismos trabajos hacen de sus mejoras.

Segunda valla: la escala. Pythia-410M y un ViT-B afinado son modelos pequeños, y los fenómenos de outliers de pesos se acentúan con la escala. “A estas escalas” es parte del claim, no letra pequeña: la llanura de Q1–Q3 podría no persistir en modelos de 7B en adelante, y esa comprobación —barata, el barrido es inferencia pura— es la extensión natural que decidiría si la caracterización generaliza.

Tercera valla: de la cota a la aproximación. Proposición 1 acota con δ_v y δ_O fijos; el paso a $e/e_0 \simeq p$ los trata además como aproximadamente constantes entre gauges. Cerca del suelo esa suposición se rompe, porque el error relativo que RTN comete por fila depende de la forma de la fila y el gauge la cambia. Sobre las familias que inflan p el ajuste da exponente 0,9979; en el punto balanceado, el único régimen medido con $p < 1$, la predicción se queda corta en un 4 % en Pythia y un 8 % en ViT-B, siempre en el mismo sentido. p detecta con holgura la región peligrosa de la órbita y pierde resolución entre representantes ya próximos al suelo. Como pronóstico del error absoluto por el lado que desinfla, es un techo optimista. Aquí no se dirime la causa de ese sesgo —la escala por fila que RTN elige depende de la forma de la fila, y el gauge la cambia— y se deja consignada como límite de la cota, no como ruido.

Enlace al programa. La órbita como espacio de diseño tiene dos caras. La de compresión queda aquí caracterizada: llana sobre la clase neutra y sus vecinos, destructiva cuando p crece. La funcional —si la órbita y sus deformaciones son palanca para inducir diversidad funcional entre cabezas— es objeto del programa de atribución por componente que continúa a [1], donde la pregunta se aborda por intervención y no por muestreo.

Reproducibilidad

Código de los barridos, CSV completos (170 016 filas del barrido de regímenes, 642 048 del de condicionamiento controlado, 102 432 del re-barrido de la familia original con normas y 1 056 del punto balanceado), tablas de lectura y scripts de figuras en <https://github.com/mmunozp1/gauge-orbit-quantization>. El barrido es reproducible por semilla global. Cualquier gauge muestreado puede reconstruirse exactamente re-jugando la secuencia del generador, sin persistir las matrices. La validación end-to-end guarda de cada condición el acierto y la clase predicha

imagen a imagen, de donde salen el contraste pareado, sus intervalos y el acuerdo de argmax. Cada gauge se aplica al par y al sesgo de valor, y una compuerta verifica la invariancia del forward antes de cuantizar, condición a condición.

Una demo interactiva acompaña al código en <https://huggingface.co/spaces/ManPla/gauge-orbit-quantization-demo>. Elige un punto de la órbita y mide en vivo p , $d(\mathbf{R})$ y el error del circuito con y sin cuantizar. No reimplementa nada: ejecuta el mismo `src/` que produjo las tablas sobre un portador ligero del sector valor-salida, y una compuerta la certifica celda a celda contra los barridos publicados, con una diferencia peor de 3×10^{-15} .

Referencias

- [1] M. Muñoz Plá. The dominant direction of $\mathbf{W}_O$ is not identifiable: gauge orbit, zero certified radius, and consequences for pruning. Zenodo, v7.0.1, 2026. Concept DOI: 10.5281/zenodo.21630534.
- [2] S. Ashkboos, A. Mohtashami, M. L. Croci, B. Li, P. Cameron, M. Jaggi, D. Alistarh, T. Hoefer y J. Hensman. QuaRot: outlier-free 4-bit inference in rotated LLMs. *Advances in Neural Information Processing Systems* (NeurIPS), 2024.
- [3] Z. Liu, C. Zhao, I. Fedorov, B. Soran, D. Choudhary, R. Krishnamoorthi, V. Chandra, Y. Tian y T. Blankevoort. SpinQuant: LLM quantization with learned rotations. *International Conference on Learning Representations* (ICLR), 2025.